

# 常见、罕见和体细胞遗传变异对心房颤动发病率的影响

2025年10月19日 22:27

## 目的 (Objective)

本研究设定了两个主要目标：

- 检验多基因 (polygenic)、单基因 (monogenic, 此处指罕见变异) 和体细胞基因变异对房颤发病率的独立及联合影响。
- 开发一个整合性的基因组模型 (IGM-AF)，以期更准确地预测房颤风险。

## 设计、地点和参与者 (Design, Setting, and Participants)

- 研究设计：**这是一项大型前瞻性队列研究。
- 数据来源：**研究数据来自英国生物样本库 (UK Biobank) 的参与者，并使用了他们的全基因组测序数据。
- 参与者：**研究纳入了在2006年至2010年间招募的40至69岁的参与者。
- 随访与数据分析：**通过医院记录、死亡登记和个人自述来追踪房颤事件。研究数据的分析时间为2022年8月至2024年11月。

## 暴露因素 (Exposures)

研究的核心是建立并评估一个名为**IGM-AF**的整合基因组模型，该模型包含以下三个关键的遗传风险因素：

- 多基因风险评分 (PRS)：**代表了多个常见基因变异的累积效应。
- 复合罕见变异基因集 (Afgenet)：**代表了多个罕见但效应较强的基因变异。
- 克隆性造血相关的体细胞变异 (CHIP)：**这是一种后天获得的、与衰老相关的体细胞突变。

同时，研究人员还使用了现有的临床风险评估工具 **CHARGE-AF评分** 来估算参与者的临床风险，以便进行比较和整合。

## 主要结局和测量指标 (Main Outcomes and Measures)

- 主要结局：**研究关注的主要结果是5年内新发房颤的风险比 (Hazard Ratios, HRs)，用以衡量上述三种遗传因素 (PRS, Afgenet, CHIP) 及其相互作用对房颤风险的影响程度。
- 评估指标：**使用风险比 (HRs)、C-统计量 (C statistic, 评估模型预测准确性的指标) 和重分类指数 (reclassification indices) 来量化IGM-AF模型及其各组成部分的预测性能。

## 结果 (Results)

- 样本规模：**研究共纳入了416,085名个体，其中54%为女性，平均年龄为56.6岁。在随访期间，共发生了30,797例房颤事件。
- 独立风险：**三种遗传驱动因素均与房颤发病独立相关：
  - 多基因风险评分 (PRS) 的风险比为1.65。
  - 罕见变异基因集 (Afgenet) 的风险比为1.63。
  - 体细胞变异 (CHIP) 的风险比为1.26。
- 累积风险：**与只携带一种遗传驱动因素的个体相比，同时携带所有三种 (常见、罕见和体细胞) 遗传驱动因素的个体，其5年内发生房颤的累积风险至少高出2倍。
- 模型性能：**
  - 将整合基因组模型 (IGM-AF) 与临床风险模型 (CHARGE-AF) 相结合，其预测性能 (C-统计量为0.80) 优于单独使用IGM-AF或单独使用CHARGE-AF。
  - 在临床模型的基础上增加基因模型，能够更准确地对房颤高风险人群进行分类。

## 结论与意义 (Conclusions and Relevance)

这项队列研究的结果表明，在评估房颤的基因组风险时，常见、罕见和体细胞变异提供了互补的信息。这意味着综合利用这些全面的遗传信息，可以更有效地筛选高风险人群，并可能为制定更精准的预防干预措施提供依据。

## ★ INTRO

### 第一段：房颤的危害及遗传学研究背景

- 房颤的临床重要性：**开篇第一句就强调了心房颤动 (Atrial Fibrillation, AF) 是一种非常普遍的心律失常，它会显著增加中风、心力衰竭和过早死亡的风险。这确立了研究该疾病的重要性。
- 遗传学研究的进展：**作者指出，近几十年来，在理解房颤的遗传因素方面取得了重大进展，这些因素主要包括**生殖系变异 (germline variants)**，即遗传自父母的、存在于全身所有细胞中的基因变异。
- 两类主要的生殖系变异：**
  - 常见变异 (Common variants)：**通过**全基因组关联研究 (GWAS)**，科学家们已经识别了数百个与房颤相关的基因位点。这些常见变异单个效应通常较弱 (modest effect sizes)，但累积起来会增加风险。
  - 罕见变异 (Rare germline variants)：**这类变异更为稀少，但通常效应更强 (larger effects)。特别是那些导致**功能丧失 (Loss of Function, LoF)** 的变异，可能会在某些亚群中导致早发性房颤。
- 引出知识空白：**尽管对这些遗传性变异的认识在不断增长，但科学家们对于**\*\*多基因因素 (polygenic, 即多个常见变异的累积) 和单基因因素 (monogenic, 即单个罕见变异)\*\***是如何独立以及如何共同作用导致房颤的，仍不完全清楚。这是本研究要解决的第一个核心问题。

### 第二段：引入体细胞变异及其复杂性

- 引入第三类变异——体细胞变异：**作者引入了一个更复杂的层面：**体细胞基因变异 (Somatic gene variants)**。这类变异并非遗传自父母，而是个体在生命过程中后天获得的，仅存在于身体的部分细胞中。
- 关键的体细胞变异——CHIP：**特别提到了**\*\*“意义不明的克隆性造血” (Clonal Hematopoiesis of Indeterminate Potential, CHIP)\*\***。这是一种与衰老相关的现象，指血细胞中的某些体细胞突变。
- CHIP与房颤的关联：**研究已经发现，特定基因 (如 *TET2* 和 *ASXL1*) 的克隆性造血与房颤风险增加有关。进一步的研究还揭示了其潜在机制：源自 *TET2* 突变的CHIP对房颤风险的影响，很可能是通过激活 **Nlrp3炎症小体 (Nlrp3 inflammasome)** 通路来驱动的。
- 生殖系变异与体细胞变异的联系：**作者强调，虽然生殖系变异是遗传的，而体细胞变异是后天获得的，但两者并非完全独立。越来越多的证据表明，某些特定的生殖系变异 (尤其是在DNA修复基因上的变异) 可能会使个体更容易产生体细胞变异。
- 引出第二个知识空白：**然而，对于房颤风险而言，体细胞变异和遗传性的生殖系变异之间的潜在关系尚未得到充分的探索。

### 第三段：本研究的目标与方法

- 研究的立足点：**为了填补上述知识空白，本研究利用了英国生物样本库 (UK Biobank) 超过40万人的全基因组序列数据。这是一个巨大的数据优势。
- 核心研究策略：**研究团队旨在对所有已知的房颤遗传驱动因素——**常见的、罕见的和体细胞的**——进行一次综合性的探索。
- 最终目标：**通过将生殖系 (遗传的) 和体细胞 (后天的) 信息统一到一个全面的框架中，研究者希望：
  - 更完整地理解不同类型的基因变异对房颤的贡献。
  - 阐明这些不同的遗传组分是如何独立地，以及如何协同地 (synergistically) 调节个体对房颤的易感性。

## 核心内容概览

这部分主要涵盖了四个方面：

- 数据来源与伦理合规：** 说明了研究使用的数据集、授权和伦理批准。
- 数据质量控制（Quality Control, QC）：** 这是本部分的重中之重，描述了如何通过一系列严格的筛选，确保用于分析的数据是高质量和无偏差的。
- 人群信息：** 说明了参与者的种族和族裔信息是如何获得的。
- 报告规范：** 指出了本研究遵循了国际公认的流行病学研究报告指南。

## 详细解析

### 1. 数据集可用性与质量控制（Dataset Availability and Quality Control）

- 数据来源与授权：**
  - 研究使用了“英国生物样本库”（UK Biobank）的数据，这是一个大规模、长期的生物医学数据库，包含英国各地参与者的基因和健康信息。
  - 使用该数据经过了正式申请，申请ID为 89885，这表明研究的合法性和可追溯性。
  - 所有参与者都提供了书面知情同意，符合医学研究的基本伦理要求。
- 伦理批准：**
  - 研究方案获得了两个机构的伦理委员会批准：
    - 中国科学院北京基因组研究所（Beijing Institute of Genomics, Chinese Academy of Sciences）
    - 中国国家生物信息中心（China National Center for Bioinformation）
  - 这说明研究设计和执行都遵循了严格的伦理标准。

### 2. 严格的数据质量控制（QC）流程

这是确保基因关联研究结果准确可靠的关键步骤。低质量的样本或基因分型数据会产生大量的假阳性或假阴性结果。研究中应用了以下一系列筛选标准：

- variant call rate (<95%) – 变异检出率过滤：**
  - 含义：** 对于某一个基因变异位点（SNP），如果在所有样本中成功测序并得到结果的比例低于95%，那么这个位点的数据就被认为是不可靠的，将被剔除。
  - 目的：** 这通常意味着这个位点的测序探针设计不佳或存在技术问题，剔除它可以避免引入系统性的技术误差。
- sample call rate (<95%) – 样本检出率过滤：**
  - 含义：** 对于某一个参与者（样本），如果在所有检测的基因位点中，成功得到结果的比例低于95%，那么这个样本的数据将被剔除。
  - 目的：** 样本检出率低通常意味着DNA质量差或实验操作失败，这样的样本数据可信度低。
- Hardy-Weinberg equilibrium test ( $P < 1 \times 10^{-6}$ ) – 哈迪-温伯格平衡检验：**
  - 含义：** 哈温平衡是群体遗传学的基本定律，描述了一个理想群体中等位基因频率和基因型频率的关系。如果某个基因位点的实际观测频率显著偏离了理论预期（此处的P值阈值设得非常严格，为百万分之一），则可能意味着存在问题。
  - 目的：** 严重偏离哈温平衡通常是基因分型错误的信号，也可能由群体分层、近亲繁殖或选择压力等因素造成。通过这个检验可以筛掉那些分型质量可疑的基因位点。
- outliers for heterozygosity – 杂合度异常值过滤：**
  - 含义：** 计算每个样本基因组中杂合子（即等位基因不同的基因型，如Aa）的比例。如果一个样本的杂合率远高于或远低于平均水平（通常定义为偏离均值±3个标准差），则被视为异常值剔除。
  - 目的：** 杂合率过高可能表示样本被污染（混入了其他人的DNA）；杂合率过低可能表示存在近亲繁殖。剔除这些样本可以提高数据的纯净度。
- discordance between genetically inferred sex and self-reported or ambiguous sex ( $0.5 < F \text{ statistic} < 0.8$ ) – 基因推断性别与自报性别不符或性别模糊：**
  - 含义：** 通过分析X染色体的杂合率可以推断个体的遗传学性别（女性XX染色体在非假常染色体区的杂合率正常，而男性XY染色体则接近纯合）。F统计量（F-statistic）是衡量近交或杂合程度的指标，这里用它来量化X染色体的杂合情况。
  - 目的：** 如果基因推断的性别与参与者自己报告的性别不一致，或者F统计量落在了一个模糊的区间（表明性染色体可能存在异常或数据质量问题），这些样本将被剔除。这可以排除样本标签错误或性染色体非整倍体等复杂情况。
- pairwise kinship value was greater than or equal to 0.0884 (defined by second degree of relationship or closer) – 亲缘关系过滤：**
  - 含义：** 计算数据集中任意两个个体之间的亲缘关系系数。如果系数大于等于0.0884，这通常对应于二级亲属关系（如叔侄、祖孙）或更近的亲属（如兄弟姐妹、父母-子女）。在这种情况下，会从每一对亲属中移除一个样本。
  - 目的：** 标准的关联分析假设样本之间是相互独立的。如果数据集中包含大量亲属，会违反这一假设，导致结果出现偏差（假阳性）。因此，必须移除亲属样本，只保留一个代表。

### 3. 参与者种族和族裔

- 信息来源：** 参与者的种族和族裔信息直接来源于UK Biobank数据库的自我报告。
- 分类：** 包括亚洲人、黑人、华人、混血、白人和其他。研究未对这些类别进行更细致的划分。

### 4. 报告规范

- 遵循STROBE指南：** 研究遵循了\*\*“加强流行病学观察性研究报告”（Strengthening the Reporting of Observational Studies in Epidemiology, STROBE）\*\*的指南。
- 意义：** STROBE是一份国际公认的清单和指南，旨在确保观察性研究（如本研究中的队列研究）的报告是透明、完整和清晰的。遵循该指南意味着研究者在论文中清楚地报告了研究的设计、实施、分析和结果的各个方面，大大提高了研究的可信度和可重复性。[\[1\]](#) [\[2\]](#) [\[3\]](#) [\[4\]](#)

## 总结

总而言之，这段方法学描述展示了一项非常严谨和规范的基因组学研究。它不仅确保了研究的**伦理合规性**，更通过一系列精细和严格的**数据质量控制**步骤，最大程度地排除了可能导致错误结论的各种偏倚，为后续的关联分析奠定了坚实的基础。最后，遵循STRO-BE指南也体现了研究团队对科学透明度和严谨性的承诺。

## 第一部分：定义三种遗传变异（Common, Rare, and Somatic Variants）

这部分的核心是为每个参与者量化三种不同类型的遗传风险。

### 1. 常见变异（Common Variants）– 多基因风险评分（PRS）

- 目的：** 将成千上万个与房颤（AF）相关的常见基因变异的微小效应累积起来，计算出一个总体的遗传风险分数。
- 计算方法：**
  - 权重来源：** 使用了研究团队之前发表的一项大规模、多族裔的全基因组关联研究（GWAS）得出的变异权重。**这是一个关键的优点**，因为使用独立的权重集（在一个数据集里计算权重，在另一个数据集里应用）可以有效避免模型“过拟合”，使结果更可靠。
  - 计算工具：** 使用了名为 PLINK 的标准生物信息学软件来计算PRS。
  - 控制混杂因素：** 为了剥离非遗传因素的干扰，研究人员首先对原始的PRS分数进行了回归分析，校正了参与者的**年龄、性别、以及代表遗传背景的前10个主成分**

(PCs)。校正遗传主成分是为了消除由不同祖源背景（如欧洲、亚洲、非洲等）带来的基因频率差异，确保关联性是来自疾病本身而非人群结构。

- **标准化:** 最后，将校正后的PRS分数（即回归分析的残差）进行标准化，使其均值为0，标准差为1。这使得PRS分数可以在后续模型中作为一个标准的、易于解释的变量来使用。

## 2. 罕见变异 (Rare Variants) – Afdgenenet基因集

- **目的:** 识别那些携带了能够“严重破坏基因功能”的罕见变异的个体。这类变异虽然稀少，但效应强大。
- **筛选策略 (多步骤):**
  1. **候选基因:** 首先，从以往的研究中圈定出已知与房颤相关的基因。
  2. **变异注释:** 在这些基因中，利用生物信息学工具 (Ensembl Variant Effect Predictor) 筛选出被预测为\*\*功能丧失型 (Loss-of-Function, LoF)\*\* 的变异。
  3. **频率过滤:** 只保留\*\*次要等位基因频率低于1%\*\*的变异，确保其“罕见”的属性。
  4. **关联验证:** 将同一个基因内的所有符合条件的罕见LoF变异“打包”，使用Regenie软件进行**基因负荷检验 (burden test)**，以验证携带这些变异是否真的与房颤风险显著相关。这一步是为了确保纳入的基因和变异是真正有效的。
  5. **最终基因集:** 通过验证的基因被纳入最终的 **Afdgenenet** 基因集。
- **个体分类:** 最终，每个参与者被简单地分为两类：
  - **携带者 (carrier):** 在Afdgenenet基因集中的任何一个基因上，携带了至少一个符合条件的罕见LoF变异。
  - **非携带者 (noncarrier):** 不符合上述条件。

## 3. 体细胞变异 (Somatic Variants) – CHIP

- **目的:** 识别那些携带与衰老相关的、后天获得的克隆性造血 (CHIP) 变异的个体。
- **筛选策略:** 通过一个综合了**测序质量、变异注释和人群关联数据**的逐步筛选流程来确定CHIP变异。
- **关注的基因:** 重点关注那些在**表观遗传调控** (如 *TET2*, *ASXL1*, *JAK2*)、**信使RNA剪接** (如 *SF3B1*, *SRSF2*) 和**DNA损伤修复** (如 *TP53*, *PPM1D*) 等关键生物学通路中的基因。
- **关联验证:** 同样对这些基因进行了基因水平的验证，以确认其与房颤的关联。
- **个体分类:** 与罕见变异类似，参与者被分为两类: CHIP**携带者** (携带至少一个相关的CHIP变异) 和**非携带者**。

# 第二部分: 统计分析 (Statistical Analysis)

这部分描述了如何利用上面定义的两个遗传变量来回答研究问题。

## 1. 确定人群和估算效应

- **流行率计算:** 计算了PRS (按五分位数分组)、Afdgenenet携带状态和CHIP携带状态在整个队列中的普遍程度。
- **病例定义:** 房颤病例的确定综合了多种来源: 基线时的自述、住院记录和死亡登记，确保了病例认定的全面性。
- **效应量估算:** 使用 **Cox比例风险模型 (Cox proportional hazards model)** 来评估每一种遗传驱动因素对**新发房颤**风险的影响。这是一个标准的生存分析方法，可以分析不同因素如何影响事件 (这里是房颤) 发生的时间。模型同样校正了年龄、性别和10个遗传主成分。

## 2. 开发整合基因组模型 (IGM-AF)

- **目的:** 将PRS、Afdgenenet和CHIP这三个遗传驱动因素整合成一个单一的、更强大的预测模型。
- **方法:** 通过一个联合回归模型，为这三个因素分别确定最佳权重，然后将它们加权求和，得到一个综合的 **IGM-AF** 分数。这个分数同样经过了标准化处理。

## 3. 遗传风险与临床风险评分的相互作用

- **目的:** 评估新开发的遗传模型 (IGM-AF) 是否能在现有的临床风险预测工具之上提供**额外的预测价值**。
- **比较对象:** 选择了公认的临床风险评分 **CHARGE-AF**。
- **评估方法:**
  1. **C-统计量 (C-statistic):** 这是一个衡量模型**区分度**的指标，数值越高，代表模型区分“会发病”和“不会发病”人群的能力越强。研究人员比较了不同模型 (如仅临床模型 vs. 临床+遗传模型) 的C-统计量，并使用\*\*自助法 (bootstrap)\*\* 来检验这种提升是否具有统计学意义。
  2. **净重分类指数 (Net Reclassification Index, NRI):** 这是一个评估模型**风险分类改善**的指标。它量化了当加入新指标 (IGM-AF) 后，有多少比例的患者被更准确地划分到了更高或更低的风险类别中。

## 4. 总体统计设定

- **软件:** 所有分析均使用 R 语言 (版本 4.2.2) 完成。
- **显著性水平:** P值均为双侧检验，并以 **P < .05** 作为统计学显著性的判断标准。

# 总结

总的来说，这部分方法学展示了一个设计精良、执行严谨的研究流程。它不仅 meticulously 地定义和验证了三种不同类型的遗传风险，还使用了先进的统计模型来整合这些信息，并通过与现有临床工具的直接比较，严格评估了其潜在的临床应用价值。每一步都考虑了潜在的偏倚和混杂因素，并采取了相应的控制措施，大大增强了研究结果的科学性和可信度。

